ANÁLISE EXPLORATÓRIA DOS DADOS

Cálculo Computacional e Estatística

Correlação, regressão e análise dos dados de monitoramento

Grupo 06

Arthur Vitorio

Enzo Quinalha

Emanuelly Melo

Gustavo Lima

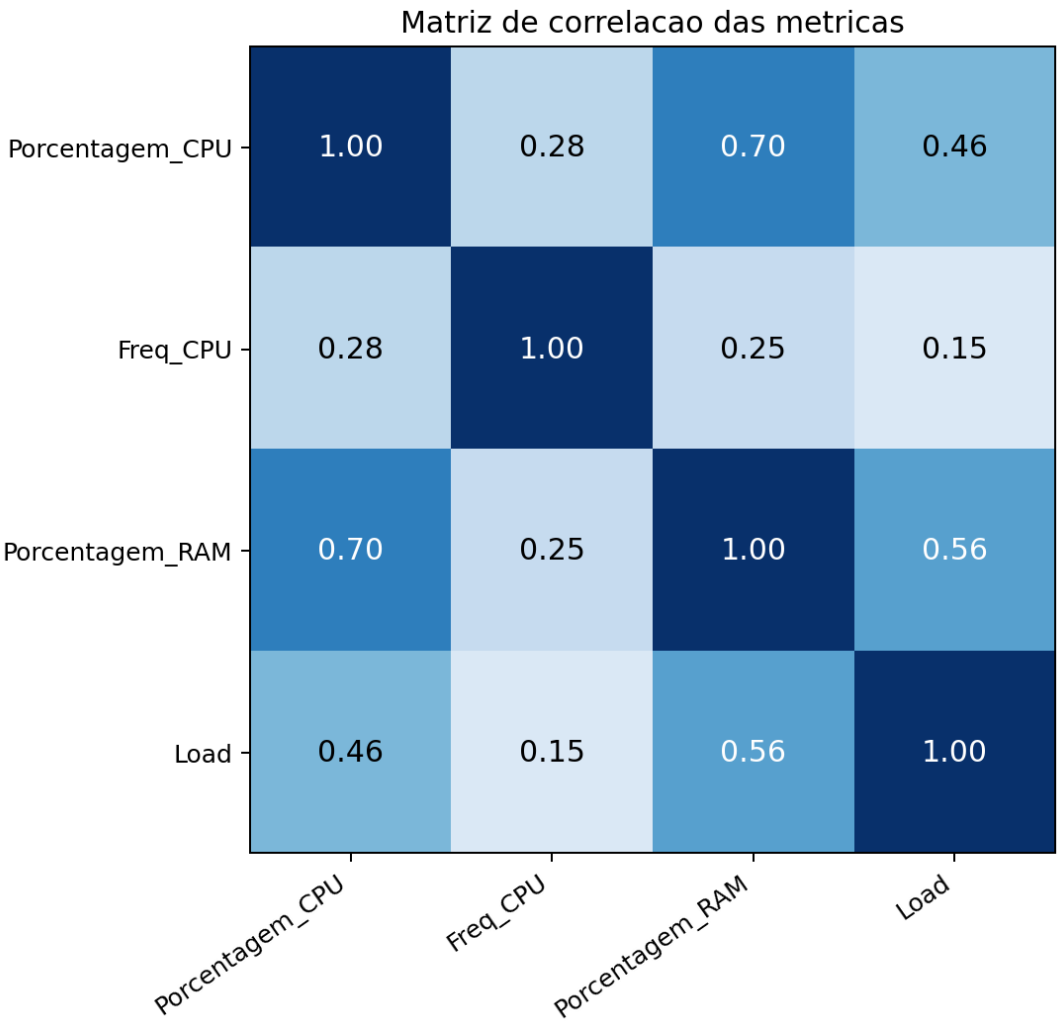
Rafael Naleto

Contexto

O objetivo desta análise é verificar como as principais métricas da máquina se relacionam. Foram analisados o uso de CPU, a frequência do processador, o uso de RAM e o Load. Além da matriz de correlação, foram usados gráficos de dispersão com regressão e um boxplot para comparar o uso da CPU.

Matriz de correlação

A matriz mostra o quanto duas variáveis tendem a variar juntas. Valores próximos de 1 indicam uma relação positiva forte, valores próximos de 0 indicam pouca relação linear e valores negativos indicam uma relação inversa.



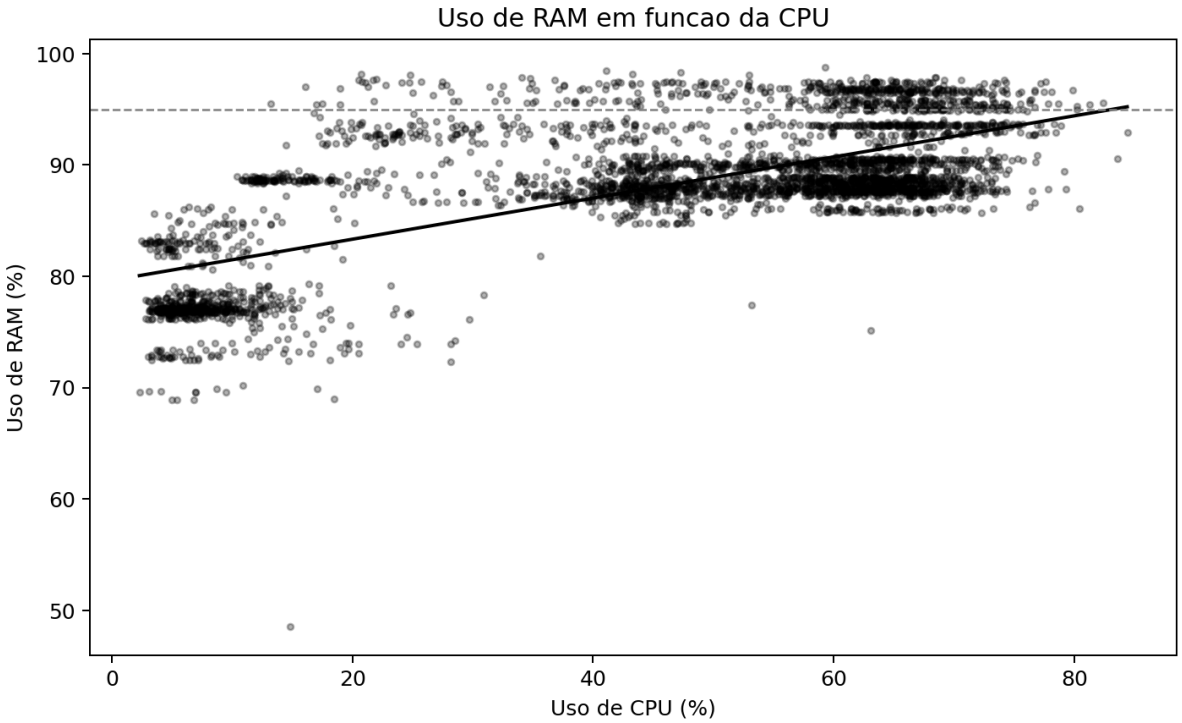
Oprincipal resultado é a relação entre CPU e RAM. O valor de 0,70 mostra que, nesta coleta, quando o uso da CPU aumenta, o uso da RAM também tende a aumentar. Isso não significa que uma variável seja a causa da outra, mas mostra que as duas aparecem associadas em boa parte dos registros.

A relação entre RAM e Load também chama atenção, com 0,56. Já CPU e Load apresentam uma relação menor, de 0,46. Isso mostra que o Load não acompanha a CPU de forma tão direta quanto a

RAM. Para o monitoramento, isso é útil porque reforça a ideia de observar mais de uma métrica ao mesmo tempo.

CPU x RAM

O gráfico abaixo mostra cada registro como um ponto e a reta representa a tendência encontrada pela regressão linear.

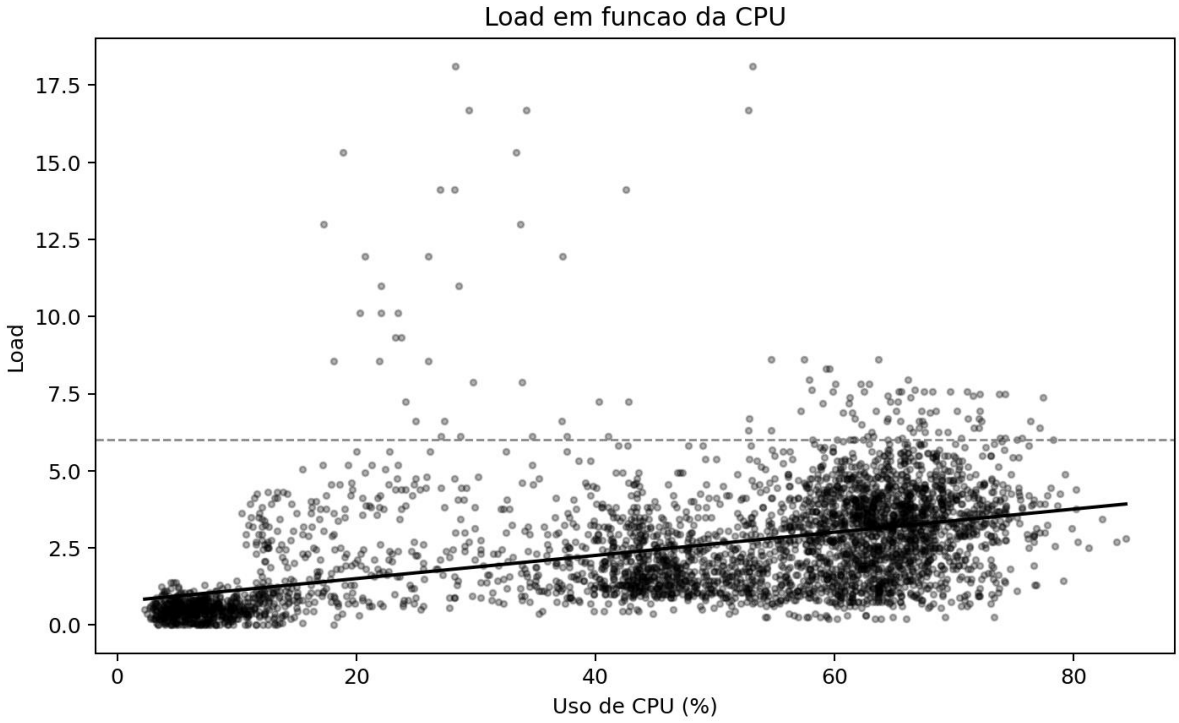


O gráfico mostra uma tendência crescente: os pontos tendem a subir conforme a CPU aumenta. Isso confirma visualmente a correlação de 0,70 da matriz. Porém, os pontos estão bastante espalhados, então existem momentos em que a CPU apresenta um valor parecido e a RAM está em níveis diferentes.

O modelo obtido foi RAM = 79,63 + 0,1848 × CPU, com $R^2 = 0,487$. Em termos simples, o modelo consegue explicar cerca de 48,7% da variação observada na RAM usando apenas a CPU. Isso é útil para mostrar que existe uma relação, mas também deixa claro que outros fatores influenciam o uso de memória.

CPU e RAM podem ser acompanhadas juntas. Uma subida das duas ao mesmo tempo pode ser um sinal de aumento de carga, mas a CPU não deve ser usada como único indicador para prever uma possível pressão de memória.

CPU x Load

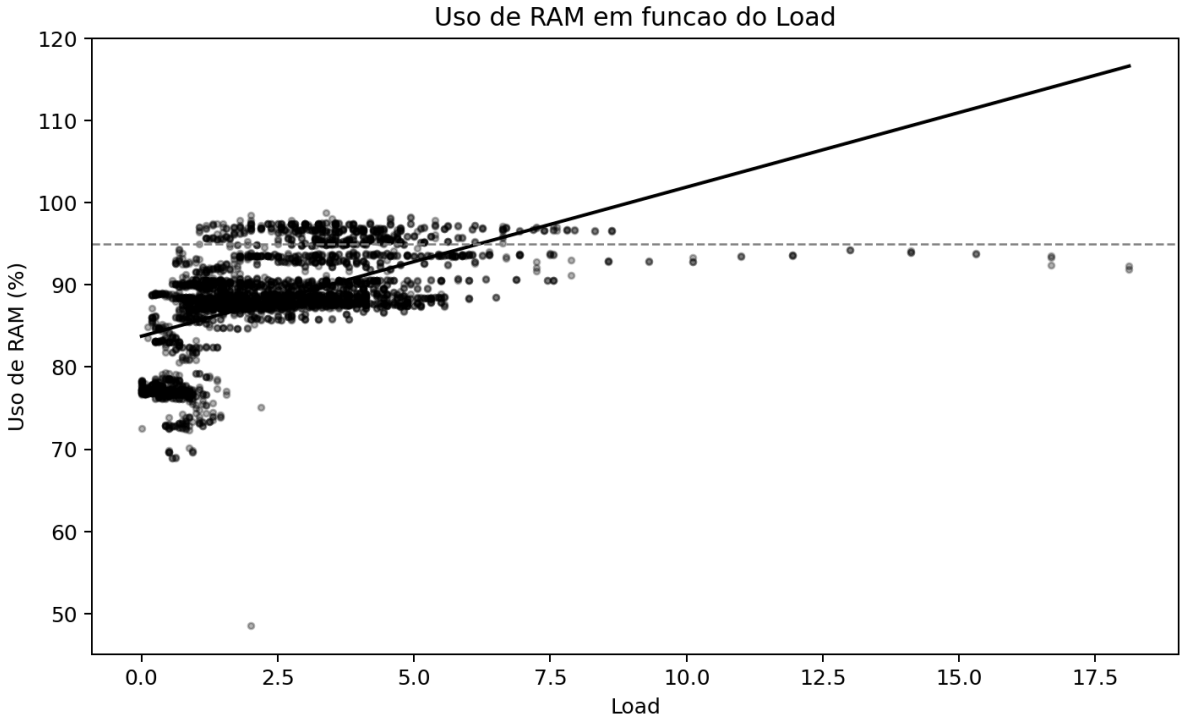


A correlação entre CPU e Load foi de 0,46. A reta do gráfico apresenta uma tendência positiva, mas os pontos estão bem espalhados. Isso mostra que o Load aumenta em alguns momentos junto com a CPU, mas não acompanha o processador de maneira tão forte.

A regressão resultou em Load = 0,7539 + 0,03755 × CPU, com $R^2 = 0,210$. Portanto, apenas 21,0% da variação do Load é explicada pela CPU nesse modelo. O valor baixo do R^2 é importante: ele mostra que olhar somente para o uso da CPU não é suficiente para entender o Load da máquina.

Um sistema de monitoramento que verificasse apenas a CPU poderia deixar passar mudanças no Load. As duas métricas devem ser analisadas de forma complementar.

Load x RAM



A correlação entre Load e RAM foi de 0,56, indicando uma relação positiva moderada entre as duas variáveis. Isso significa que, de forma geral, quando o Load aumenta, o uso de RAM também tende a aumentar. Porém, os pontos apresentam bastante dispersão, mostrando que o Load não depende somente da utilização da memória.

Um comportamento interessante pode ser observado quando o uso de RAM se aproxima de 100%. Como a utilização da memória não pode continuar aumentando indefinidamente, os pontos próximos desse limite passam a apresentar valores maiores de Load. Isso pode indicar que a máquina está se aproximando de uma situação de saturação: em vez de simplesmente aumentar o percentual de RAM utilizado, o aumento da demanda passa a aparecer como maior carga de trabalho no sistema.

Esse comportamento é importante para o monitoramento porque mostra que observar somente a RAM pode não ser suficiente. Uma máquina utilizando 90% ou 95% da memória já pode estar próxima de uma situação de pressão, mesmo que a RAM ainda não tenha atingido 100%. Se, ao mesmo tempo, o Load continuar aumentando, isso pode ser um sinal de que a infraestrutura está começando a ter dificuldade para atender à demanda.

Portanto, a relação entre Load e RAM pode ser utilizada como um indicador complementar. Quando os dois valores aumentam juntos e a RAM se aproxima do seu limite, o comportamento merece atenção, pois pode representar uma situação de pressão sobre os recursos da máquina. No contexto do monitoramento de infraestrutura, esse tipo de comportamento pode ajudar a identificar problemas antes que ocorra uma indisponibilidade do serviço.

Resultado

A principal informação encontrada é que não existe uma única métrica que explique todo o comportamento da máquina. CPU e RAM possuem a relação mais forte entre as variáveis analisadas, mas essa relação ainda deixa uma parte importante do comportamento sem explicação.

A RAM merece atenção especial porque apresentou média de 88,33% e chegou a 98,8%. Isso significa que a memória permaneceu em um nível relativamente alto durante boa parte da coleta. Como a CPU não explica toda a variação da RAM, seria importante manter um acompanhamento independente da memória.

A maior correlação foi entre CPU e RAM (0,698), seguida por RAM e Load (0,561) e CPU e Load (0,459). Os gráficos de dispersão confirmam essas tendências, mas também mostram bastante dispersão, indicando que uma métrica não explica sozinha o comportamento da outra.

O resultado mais útil para o projeto é justamente essa combinação. CPU, RAM e Load devem ser observados juntos, porque cada um mostra uma parte diferente do estado da máquina. A regressão de CPU e RAM, por exemplo, consegue explicar cerca de 48,7% da variação da RAM, mas ainda existe uma grande parcela que depende de outros fatores.